

基于 AdaBoost 的公交客流量统计算法^{*}

王璇¹, 李倩丽², 宋焕生¹, 孙士杰¹, 崔华¹

(1. 长安大学信息工程学院, 西安 710064; 2. 国家测绘地理信息局第一航测遥感院, 西安 710054)

摘要: 为解决复杂场景目标识别中伪目标的干扰问题,采用基于 AdaBoost 分类的方法分析疑似目标的三维轨迹,结合真实目标共有的特征信息,进一步分类真实目标与伪目标。首先,根据深度相机获取的深度图像提取疑似目标的人头区域,利用 Kalman 滤波跟踪得到二维轨迹;其次,通过摄像机标定将目标的二维轨迹转换为空间中的三维轨迹;最后,利用 AdaBoost 训练正负样本得到强分类器,进一步分类真实目标与伪目标。实验结果表明,该方法能够有效地提高目标识别的精度,对复杂场景下的目标识别具有良好的适应性。

关键词: AdaBoost 分类; 3D 轨迹; 深度相机; 卡尔曼滤波; 摄像机标定

中图分类号: TP391.4 **文献标志码:** A **文章编号:** 1001-3695(2018)03-0949-04

doi:10.3969/j.issn.1001-3695.2018.03.065

Statistical algorithm for bus passenger flow based on AdaBoost

Wang Xuan¹, Li Qianli², Song Huansheng¹, Sun Shijie¹, Cui Hua¹

(1. School of Information Engineering, Chang'an University, Xi'an 710064, China; 2. The First Institute of Aero-photogrammetry & Remote Sensing, State Bureau of Surveying & Mapping, Xi'an 710054, China)

Abstract: In order to solve the interference of pseudo target for the object recognition in complex scenes, this paper used the AdaBoost classifier to analyze the 3D trajectory of suspected object. It combined the feature information of the objects to classify the real objects from the false objects. Firstly, it used a depth camera to obtain the depth image and extracted the head region of suspected objects, and it adopted a Kalman filter to track the 2D trajectory on the image. Secondly, the method converted the 2D trajectory to 3D trajectory in space using the camera calibration. Finally, it applied the AdaBoost classifier to train the positive and negative samples, and it got a strong classifier. It used the strong classifier to further distinguish real targets from pseudo target. Experimental results show that this method can improve the accuracy of object identification effectively. It has a good adaptability for object recognition in complex scenes.

Key words: AdaBoost classifier; 3D trajectory; depth image; Kalman filter; camera calibration

目前智能交通监控系统关注的重点是如何从交通监控系统中检测并识别出运动的目标。运动目标视频检测技术可以应用在大型商场、公交车以及地铁等人员密集的复杂场景中对其进行客流量的实时统计。在交通监控系统中,人们往往关注的重点是监控场景中的运动目标,然而在实际场景中,由于光照干扰、摄像机抖动以及目标之间互相遮挡等问题会对目标检测造成干扰,这些干扰增加了精确检测目标的难度^[1]。

在交通视频监控系统中,能够直接获取的信息就是视频图像信息,图像是对客观事物最直观的描述,其中包含事物的大部分静态信息,如颜色、形状、大小等;视频是对客观事物的动态描述,其包含了事物的部分动态信息,如运动方向、速度等^[2]。近年来,许多学者进行了相关方面的研究。Viola 等人^[3]采用了 Haar 特征来描述物体,并用模式识别的方法训练级联分类器,其中每一级的子分类器由多个 Haar 特征构成。Schwartz 等人^[4]通过计算局部区域的 HOG 特征,描述待检测目标的轮廓。该特征对光照和少量偏移不敏感。此外,常用的特征还包括 SIFT^[5]、SURF^[6]、Gabor^[7]、边缘、颜色特征等。当

待检测目标具有明显的形状特征时,使用基于统计学习的运动目标检测方法可以获得很好的检测效果。现阶段常用的分类器有 AdaBoost 算法、C4.5、朴素贝叶斯分类器以及支持向量机 SVM 和神经网络^[8~12]。Hamarneh 等人^[13]提出了一种通过将形状与外观相结合来提高分水岭分割的新方法,克服了一些分水岭变换的内部问题。Neri 等人^[14]使用高阶统计量(HOS)来进行目标分割,结合了基于运动信息的高阶统计量和基于变化检测的高阶统计量。柯海峰等人^[15]提出了一种基于变形模板技术的目标轮廓跟踪方法,可以适应目标旋转、尺度、场景光照等变化。

1 AdaBoost 分类

AdaBoost 算法是通过改变训练样本的分布权重,进而得到不同的测试样本集。它的特点是每次训练完成后,得到一个最优弱分类器,并根据其分类误差获得构成强分类器时各个弱分类器的权重。同时,根据每次训练结果,增大错误分类的样本

收稿日期: 2016-10-10; **修回日期:** 2016-12-14 **基金项目:** 国家自然科学基金资助项目(61572083);陕西省自然科学基金基础研究计划资助项目(2015JZ018);中央高校基本科研业务费资助项目(自然科学类)(310824152009,310824163411)

作者简介: 王璇(1991-),女,山东威海人,博士研究生,主要研究方向为交通视频图像处理、模式识别(jessica036@126.com);李倩丽(1989-),女,硕士,主要研究方向为机器视觉的交通感知、模式识别;宋焕生(1964-),男,教授,博导,主要研究方向为图像处理与人工智能、智能交通理论、关键技术;孙士杰(1989-),男,博士研究生,主要研究方向为机器视觉、人工智能;崔华(1976-),女,教授,主要研究方向为图像分析、数据挖掘、机器学习及其在智能交通中的应用。

权重,减小正确分类样本的权重,进而重新得到一个新的训练样本集。在接下来的训练过程中,重点关注错误分类样本的比值。当循环次数达到预先设定的最大循环次数或者组合的强分类器的分类误差小于预先设定的分类误差阈值时,则停止循环,并将各弱分类器按照其对应的权重组合得到最终的强分类器。

给定一个样本空间集 $S = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, X 为样本空间, Y 为标记集合且 $Y = \{1, -1\}$, 其中 $x_i \in X, y_i \in Y$ 。具体的算法流程如下:

a) 初始化训练样本的权重, 而且每一个训练样本的初始权重为 $1/N$ 。

$$D_1 = (w_{11}, w_{12}, \dots, w_{1i}, \dots, w_{1N}) \quad w_{1i} = \frac{1}{N}; i=1, 2, \dots, N \quad (1)$$

b) 训练弱分类器。用 $m=1, 2, \dots, M$ 代表迭代次数, 即能够生成的弱分类器个数。

(a) 对权重分布为 D_m 的样本进行训练学习, 选取使检测错误率最低的阈值作为当前弱分类器。

$$G_m(x): x \rightarrow \{-1, 1\} \quad (2)$$

(b) 计算 $G_m(x)$ 在训练样本上的分类误差。

$$e_m = P(G_m(x_i) \neq y_i) = \sum_{i=1}^N w_{mi} I(G_m(x_i) \neq y_i) \quad (3)$$

(c) 计算 $G_m(x)$ 的系数 α_m 。 α_m 代表 $G_m(x)$ 在最终强分类器中的重要程度。

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m} \quad (4)$$

(d) 更新训练样本的权重, 得到下一轮的训练样本。

$$D_{m+1} = (w_{m+1,1}, w_{m+1,2}, \dots, w_{m+1,i}, \dots, w_{m+1,N}) \quad (5)$$

$$w_{m+1,i} = \frac{w_{mi}}{Z_m} \exp(-\alpha_m y_i G_m(x_i)) \quad i=1, 2, \dots, N \quad (6)$$

$$Z_m = \sum_{i=1}^N w_{mi} \exp(-\alpha_m y_i G_m(x_i)) \quad (7)$$

其中: Z_m 是规范化因子, 使得 $\sum_{i=1}^N D_{m+1}(x_i) = 1$ 。

c) 将各个弱分类器组合为一个强分类器。

$$G(x) = \text{sign}\left(\sum_{m=1}^M \alpha_m G_m(x)\right) \quad (8)$$

因此, 可以得到 AdaBoost 分类算法流程如图 1 所示。




图1 AdaBoost 分类算法流程

2 运动目标三维轨迹获取

本文利用深度相机获取图像的深度图, 采用寻找局部深度最大的方法在深度图中提取目标的人头区域, 实现对疑似目标的检测。通过 Kalman 滤波器对目标匹配搜索区域进行预测, 实现对目标的跟踪, 获得其在图像中的二维轨迹。通过对相机进行三维标定, 可以获得乘客运动轨迹的三维信息, 将对应的三维轨迹在三维空间中显示, 如图 2 所示。

相机的三维标定中利用了图像像素坐标系与世界坐标系之间的转换关系:

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} C_{11} & C_{12} & C_{13} & C_{14} \\ C_{21} & C_{22} & C_{23} & C_{24} \\ C_{31} & C_{32} & C_{33} & C_{34} \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (9)$$

从式(9)可知, 至少需要已知六个点的图像像素坐标 (u, v) 和世界坐标 (X_w, Y_w, Z_w) 参数, 才可以计算出图像像素坐标系与世界坐标系之间的变换矩阵 C 。本文在摄像机三维标定时选择了八个点, 其世界坐标系和图像坐标系中的位置如图 3 所示。已知深度图中的高度值 Z_w , 可以计算图像中任意一点 (u, v) 对应的世界坐标 (X_w, Y_w, Z_w) 。




图2 二维轨迹与三维轨迹对应图





图3 实际场景三维标定

3 AdaBoost 训练

3.1 构造训练样本

利用传统的检测与跟踪算法获得的目标运动轨迹, 会包含常规的乘客上、下车轨迹, 也会包含一些干扰轨迹, 如错误检测的跟踪轨迹 (如人手轨迹、手持物体轨迹) 以及由于光照导致轨迹跟断后重新跟踪的轨迹。本文通过人工标定的方法, 构造了一个包含 700 条三维轨迹的训练样本, 其中正样本 600 条, 负样本 100 条, 如图 4、5 所示。



(a)上车 (b)下车

图4 正样本三维图

(a)上车 (b)下车

图5 负样本三维图

3.2 训练强分类器

3.2.1 特征提取

通过分析研究轨迹特征的共同特点, 提取出以下七个特征, 分别为:

a) 轨迹点数。一条轨迹上跟踪得到的人头个数, 记为特征变量 F_1 。

b) 在 Y 方向上的跨度。一条轨迹的长度在 Y 方向上的分量, 记为特征变量 F_2 。

c) 在 Z 方向上的跨度。一条轨迹的长度在 Z 方向上的分

量,记为特征变量 F_3 。

d) 平均人头大小。一条跟踪轨迹中包含的所有人头大小(人头面积)的平均值,记为特征变量 F_4 。

e) 轨迹与拟合标准轨迹之间的欧氏距离,记为特征变量 F_5 。

首先用均值法计算得到拟合标准轨迹数据:

$$\text{standardline. } Z[y] = \frac{1}{m} \sum_{i=1}^m \text{lines}[i]. Z[y] \quad (10)$$

其中: $\text{standardline. } Z[y]$ 为拟合标准轨迹中 Y 坐标值为 y 时对应的 Z 坐标值; m 为训练样本集中正样本的个数; $\text{lines}[i]. Z[y]$ 为第 i 个训练样本 Y 坐标值为 y 时对应的 Z 坐标值。

然后对当前轨迹内部 Y 坐标对应 Z 坐标值为空的点,用线性插值的方法进行插值,公式如下:

$$\text{line. } Z[j] = \text{line. } Z[s] + \frac{\text{line. } Z[e] - \text{line. } Z[s]}{e - s} \times (j - s) \quad (11)$$

其中: $\text{line. } Z[j]$ 为当前轨迹待插入点的 Z 坐标值; j 为该点最对应的 Y 坐标值,且 $s < j < e$ 。计算当前轨迹与标准轨迹之间的欧氏距离:

$$\text{averDis} = \frac{1}{n} \sum_{y=\min}^{\max} \text{abs}(\text{line. } Z[y] - \text{standardline. } Z[y]) \quad (12)$$

f) 轨迹与拟合标准轨迹的相似度,记为特征变量 F_6 。

$$\text{dis}[y] = \text{abs}(\text{line. } Z[y] - \text{standardline. } Z[y]) \quad (13)$$

$$\text{similarity} = \sqrt{\frac{1}{n} \sum_{y=1}^L (\text{dis}[y] - \text{averDis})^2} \quad (14)$$

其中: similarity 为当前轨迹与拟合标准轨迹的相似度; $\text{dis}[y]$ 为当前轨迹和拟合标准轨迹的 Y 坐标值同为 y 时 Z 坐标值的差值。

g) 轨迹的斜率。用最小二乘拟合的方法将当前轨迹拟合成一条直线,并计算该直线的斜率,记为特征变量 F_7 。

3.2.2 特征筛选

由于训练样本数量的问题,各个特征变量的概率分布统计效果不显著,所以在进行特征变量筛选之前,本文对各个特征变量的概率统计分别作分段及平滑处理。首先,以 10 个单位为一,将每段中的 10 个单位的概率统计值相加,其总和为该段中每个单位的概率统计值;然后,用均值滤波对各个特征变量的概率统计分布图作平滑处理。经过分段、平滑后的各特征变量的概率统计分布图如图 6 所示。

从各个特征的概率统计分布图中可以分析得出,前五个特征属性无论是在上车还是下车,正负样本的分布情况都存在明显的差异,它们具有不同的分布区间,其对于正负样本的区分能力较高;而对于特征属性 F_6 和 F_7 ,从其概率分布图中可以看出,正负样本都分布在相同的区间范围内,峰值的分布也没有太大差异,其对于正负样本的区分能力较弱。因此,本文采用了轨迹点数、在 Y 方向上的跨度、在 Z 方向上的跨度、平均人头大小以及轨迹与拟合标准轨迹之间的欧氏距离这五个特征属性来进行 AdaBoost 分类。

选定特征之后,利用 AdaBoost 分类原理,训练样本使其生成一个强分类器。为防止出现过拟合现象,需要设置最大迭代次数。针对不同的实验数据,最大迭代次数可以不同。经测试,本实验数据当迭代次数为 500 时,检测精度已趋于稳定,如图 7 所示。因此,在本实验数据中当组合强分类器的分类误差小于 0.05 时,或者迭代次数大于 500 次时,则迭代终止。每一次迭代过程中自动选择一个误差最小阈值作为最优弱分类器,迭代终止时,将每次迭代选择的最优弱分类器组合得到一个强分类器。

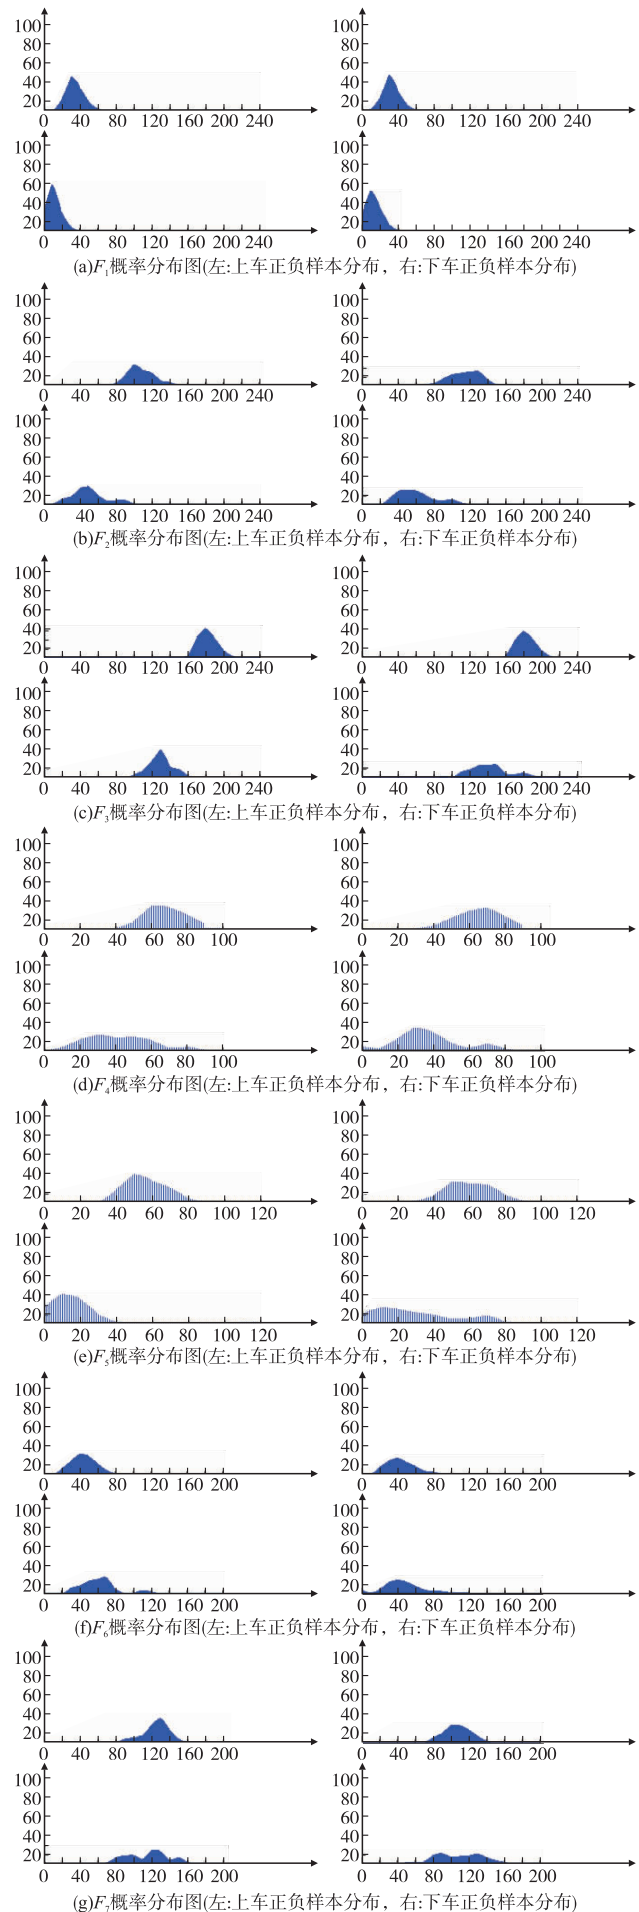


图6 概率统计分布图




图7 测试精度与迭代次数关系

4 实验结果与分析

为了验证基于 AdaBoost 分类的公交客流量统计算法的有效性,本文采用的实验数据为 2015 年 5 月 9 日在银川市 301 路公交车所采集的视频,从筛选的五个样本特征属性中,挑选其中四个特征属性进行任意组合训练以及将五个特征组合起来训练分别得到不同的强分类器,测试其检测精度,如图 8 所示。

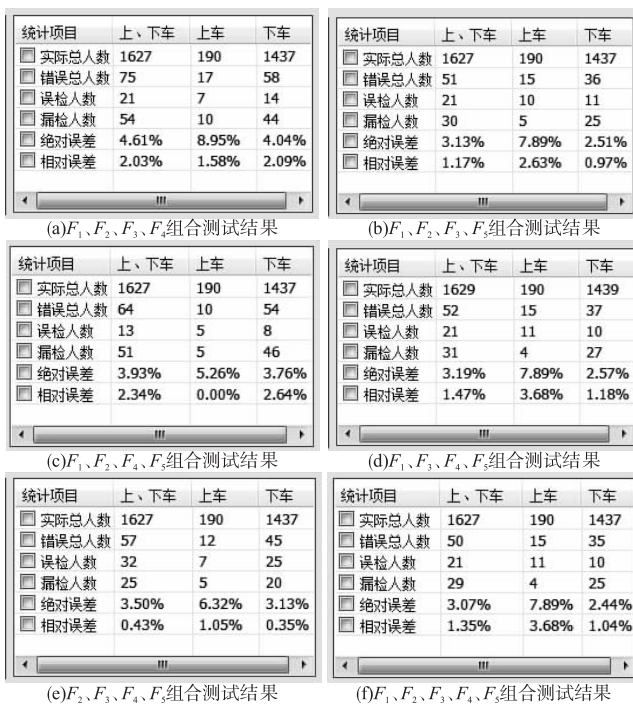


图8 特征测试结果

从图 8 中可以看出,在选择属性特征个数相同的情况下,选择不同的特征属性组合训练 AdaBoost 分类器得到的结果是不一样的。其中,图 8(b) 情况下,其整体测试精度最高,绝对误差最小,且针对下车目标的识别精度最高;(c) 情况下,误检人数最少,且针对上车目标识别精度最高;(e) 情况下,漏检人数最少,且相对误差最小。而同时选择五个特征训练,其整体绝对误差最小,因此实际应用中针对不同的需求应选择合适的特征组合进行训练。

本文将 AdaBoost 分类算法与朴素贝叶斯分类算法进行对比分析,同时采用五个特征在同一场景下的测试结果,如表 1 所示。从表 1 中可以得出,基于 AdaBoost 分类的 3D 轨迹分析与目标识别算法总体精度可以达到 96.93%,在误检和漏检人数相互抵消的情况下可以达到 98.65%,其总测试精度高于基于朴素贝叶斯分类算法 94.84% 的测试精度,在总的检测精度上提高了 2.09%;在误检和漏检人数方面,测试误差均明显减小。

表1 两种算法测试结果对比

对比项	上、下车		上车		下车	
	贝叶斯分类	AdaBoost 分类	贝叶斯分类	AdaBoost 分类	贝叶斯分类	AdaBoost 分类
实际总人数	1 627	1 627	190	190	1 437	1 437
错误人数	84	50	26	15	58	35
误检人数	30	21	16	11	14	10
漏检人数	54	29	10	4	44	25
绝对误差/%	5.16	3.07	13.68	7.89	4.04	2.44
相对误差/%	2.21	1.35	3.16	3.68	2.09	1.04

5 结束语

本文首先针对公交场景中乘客上、下车三维轨迹的特征分析,筛选出了五个具有代表性的特征,分别为轨迹点数、在 Y 方向上的跨度、在 Z 方向上的跨度、平均人头大小、轨迹与拟合标准轨迹之间的欧氏距离,实现分类器的训练,将训练得到的最优弱分类器组合得到一个强分类器,并对训练样本外的测试样本进行精度测试。实验分析表明,通过 AdaBoost 训练的强分类器在公交人数统计中具有较好的检测精度,适用于公交客流量统计系统。

参考文献:

- [1] 左凤艳. 基于特征点的运动目标检测和跟踪算法研究[D]. 济南: 山东大学, 2009.
- [2] 席阳. 基于运动特征的目标检测识别[D]. 西安: 长安大学, 2015.
- [3] Viola P, Jones M, Snow D. Detecting pedestrians using patterns of motion and appearance[C]//Proc of the 9th International Conference on Computer Vision. 2003: 734-741.
- [4] Schwartz W R, Kembhavi A, Harwood D, et al. Human detection using partial least squares analysis[C]// Proc of the 12th International Conference on Computer Vision. 2009: 24-31.
- [5] Lowe D. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [6] Hsieh J W, Chen L C, Chen Duanyu. Symmetrical SURF and its applications to vehicle detection and vehicle make and model recognition [J]. IEEE Trans on Intelligent Transportation Systems, 2014, 15(1): 6-20.
- [7] Liu Chengjun, Wechsler H. Gabor feature based classification using the enhanced fisher linear discriminant model for face recognition[J]. IEEE Trans on Image Processing, 2002, 11(4): 467-476.
- [8] Freund Y, Schapire R. A decision-theoretic generalization of on-line learning and an application to boosting[J]. Journal of Computer and System Sciences, 1997, 55(1): 119-139.
- [9] Viola P, Jones M J. Robust real-time face detection[J]. International Journal of Computer Vision, 2004, 57(2): 137-154.
- [10] Quinlan J R. C4. 5: programs for machine learning[M]. San Francisco: Morgan Kaufmann Press, 1993.
- [11] Kotsiantis S B, Zaharakis I, Pintelas P. Supervised machine learning: a review of classification techniques[J]. Informatica, 2007, 31(3): 249-268.
- [12] Cortes C, Vapnik V. Support vector machine[J]. Machine Learning, 1995, 20(3): 273-297.
- [13] Hamarneh G, Li Xiaoxing. Watershed segmentation using prior shape and appearance knowledge[J]. Image and Vision Computing, 2009, 27(1-2): 59-68.
- [14] Neri A, Colonnese S, Russo G, et al. Automatic moving object and background separation[J]. Signal Processing, 1998, 66(2): 219-232.
- [15] 柯海峰, 刘伟宁. 基于变形模板技术的目标轮廓跟踪算法[J]. 微电子学与计算机, 2008, 25(6): 197-200.